

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI TP. HỒ CHÍ MINH
VIỆN ĐÀO TẠO CHẤT LƯỢNG CAO



BÀI BÁO CÁO

ỨNG DỤNG HỌC SÂU VÀ TRÍ TUỆ NHÂN TẠO CÓ THỂ GIẢI THÍCH TRONG PHÁT HIỆN, PHÂN LOẠI KHỐI U NÃO TRÊN ẢNH MRI

(Đề tài: *BrainTumorAI* - *EfficientNetB0* / *DenseNet121* & *Grad-CAM*)

Môn : Đồ án thực tế khoa học dữ liệu
Giảng viên HD : Trần Thế Vinh
Mã lớp môn học : 010412710702
Danh sách sinh viên :

STT	Họ và Tên	MSSV	Tiến độ
1	Huỳnh Thế Hy	051205009083	100%
2	Bùi Cao Tự	052205014948	100%
3	Nguyễn Quốc Triệu	051205004949	100%

TP. Hồ Chí Minh, ngày 17 tháng 07 năm 2026

LỜI CAM ĐOAN

Nhóm chúng em xin cam đoan bài báo cáo với đề tài “Ứng dụng học sâu và trí tuệ nhân tạo có thể giải thích trong phát hiện, phân loại khối u não trên ảnh MRI” là công trình nghiên cứu do chính nhóm chúng em thực hiện, dưới sự hướng dẫn của giảng viên phụ trách môn học.

Các số liệu, kết quả thực nghiệm (độ chính xác, chỉ số Precision/Recall/F1, AUC-ROC, thời gian huấn luyện...) trình bày trong báo cáo được trích xuất trực tiếp từ quá trình huấn luyện và đánh giá mô hình trên mã nguồn dự án thực tế, không sao chép từ bất kỳ báo cáo nào khác dưới bất kỳ hình thức nào.

Mọi tài liệu tham khảo được sử dụng trong báo cáo đều được trích dẫn rõ nguồn gốc và liệt kê đầy đủ trong phần tài liệu tham khảo.

Nhóm chúng em xin chịu hoàn toàn trách nhiệm về lời cam đoan này.

TP. Hồ Chí Minh, ngày 17 tháng 07 năm 2026

Sinh viên thực hiện

MỤC LỤC

MỞ ĐẦU	I
1. Lý do chọn đề tài	I
2. Mục tiêu nghiên cứu	I
3. Đối tượng và phạm vi nghiên cứu	II
4. Phương pháp nghiên cứu	II
CHƯƠNG 1: CƠ SỞ LÝ THUYẾT.....	1
1.1 Tổng quan về khối u não và ảnh MRI	1
1.2 Mạng nơ-ron tích chập (Convolutional Neural Network - CNN).....	1
1.3 Học chuyển giao (Transfer Learning)	1
1.4 Kiến trúc mô hình sử dụng	2
1.4.1 EfficientNetB0.....	2
1.4.2 DenseNet121	2
1.5 Trí tuệ nhân tạo có thể giải thích - Grad-CAM	2
CHƯƠNG 2: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG	4
2.1 Phát biểu bài toán	4
2.2 Yêu cầu hệ thống	4
2.2.1 Yêu cầu chức năng	4
2.2.2 Yêu cầu phi chức năng	4
2.3 Kiến trúc tổng thể hệ thống	4
2.4 Kiến trúc mã nguồn dự án	5
2.5 Bộ dữ liệu (Dataset).....	6
2.6 Tiền xử lý dữ liệu và Data Augmentation	7
CHƯƠNG 3: HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH.....	10
3.1 Cấu hình huấn luyện.....	10
3.2 Kết quả huấn luyện EfficientNetB0	10
3.3 Kết quả huấn luyện DenseNet121	11
3.4 So sánh hai mô hình	12
CHƯƠNG 4: TRIỂN KHAI HỆ THỐNG	15
4.1 Backend - FastAPI.....	15
4.2 Frontend - Next.js.....	15
4.3 Đóng gói và triển khai bằng Docker.....	16
4.4 Kiểm thử hệ thống (Testing)	16
CHƯƠNG 5: ĐÁNH GIÁ, THẢO LUẬN VÀ HƯỚNG PHÁT TRIỂN	17
5.1 Điểm mạnh của hệ thống	17
5.2 Hạn chế và rủi ro cần lưu ý	17

5.2.1 Khoảng cách Validation → Test (Generalization Gap)	17
5.2.2 Recall thấp ở lớp Glioma.....	17
5.2.3 Precision thấp ở lớp Notumor - rủi ro bỏ lọt khối u	18
5.2.4 Tốc độ suy luận của DenseNet121	18
5.3 Khuyến nghị lựa chọn mô hình	18
5.4 Hướng phát triển tiếp theo.....	18
KẾT LUẬN	20
TÀI LIỆU THAM KHẢO	21
PHỤ LỤC	22
Phụ lục A - Hướng dẫn cài đặt và chạy hệ thống (tóm tắt)	22
Phụ lục B - Liên kết mã nguồn dự án	22

DANH MỤC CÁC TỪ VIẾT TẮT

Từ viết tắt	Ý nghĩa
AI	Artificial Intelligence - Trí tuệ nhân tạo
CNN	Convolutional Neural Network - Mạng nơ-ron tích chập
DL	Deep Learning - Học sâu
ML	Machine Learning - Học máy
XAI	Explainable Artificial Intelligence - Trí tuệ nhân tạo có thể giải thích
Grad-CAM	Gradient-weighted Class Activation Mapping
MRI	Magnetic Resonance Imaging - Ảnh cộng hưởng từ
API	Application Programming Interface
REST	Representational State Transfer
EDA	Exploratory Data Analysis - Phân tích khám phá dữ liệu
LR	Learning Rate - Tốc độ học
AUC-ROC	Area Under the Curve - Receiver Operating Characteristic
F1-score	Chỉ số điều hoà giữa Precision và Recall
CPU	Central Processing Unit
GPU	Graphics Processing Unit
ONNX	Open Neural Network Exchange
JSON	JavaScript Object Notation
UI/UX	User Interface / User Experience

DANH SÁCH BẢNG

Bảng 1.1. Bốn lớp phân loại trong bài toán Brain Tumor MRI Classification	1
Bảng 2.1. Danh sách yêu cầu chức năng	4
Bảng 2.2. Danh sách yêu cầu phi chức năng	4
Bảng 2.3. Cấu trúc thư mục và vai trò các module chính	6
Bảng 2.4. Thống kê bộ dữ liệu sử dụng.....	6
Bảng 2.5. Các kỹ thuật Data Augmentation áp dụng trong huấn luyện.....	7
Bảng 3.1. Cấu hình huấn luyện áp dụng cho cả hai mô hình	10
Bảng 3.2. Kết quả huấn luyện tốt nhất - EfficientNetB0 (Phase 2)	10
Bảng 3.3. Classification Report - EfficientNetB0 (Validation set).....	11
Bảng 3.4. Hiệu năng EfficientNetB0 trên tập Test độc lập.....	11
Bảng 3.5. Classification Report - DenseNet121 (Validation set, best val_acc = 99.46% tại epoch 12)	11
Bảng 3.6. Hiệu năng DenseNet121 trên tập Test độc lập.....	12
Bảng 3.7. Bảng so sánh tổng hợp EfficientNetB0 và DenseNet121	12
Bảng 4.1. Danh sách API Endpoint của Backend	15
Bảng 4.2. Danh sách các test case tự động (chạy bằng lệnh: pytest tests/ -v).....	16

DANH SÁCH HÌNH ẢNH

Hình 1.1. Heatmap Grad-CAM thực tế	3
Hình 2.1. Sơ đồ kiến trúc hệ thống.....	5
Hình 2.2. Biểu đồ phân bố số lượng ảnh theo từng lớp.....	7
Hình 2.3. Phân bố kích thước ảnh	8
Hình 2.4. Phân bố cường độ sáng trung bình theo nhãn	8
Hình 2.5. Phân bố ảnh mẫu	8
Hình 2.6. Ảnh trung bình.....	9
Hình 3.1. Biểu đồ Training/Validation Loss & Accuracy qua các epoch - EfficientNetB0 và DenseNet121	12
Hình 3.2. Biểu đồ so sánh các chỉ số Accuracy / Precision / Recall / F1 / AUC giữa hai mô hình	13
Hình 3.3. So sánh F1-score theo từng lớp giữa EfficientNetB0 và DenseNet121	13
Hình 3.4. Ma trận nhầm lẫn (Confusion Matrix) của hai mô hình trên tập Test.....	13
Hình 3.5. Đường cong ROC theo từng lớp của hai mô hình.....	13
Hình 3.6. Dashboard tổng hợp kết quả đánh giá mô hình.....	14
Hình 4.1. Giao diện phân tích ảnh.....	16

MỞ ĐẦU

1. Lý do chọn đề tài

Khối u não là một trong những bệnh lý thần kinh nguy hiểm, có khả năng ảnh hưởng nghiêm trọng đến sức khỏe và tính mạng người bệnh nếu không được phát hiện và điều trị kịp thời. Chẩn đoán khối u não hiện nay chủ yếu dựa vào việc đọc ảnh cộng hưởng từ (MRI) của bác sĩ chuyên khoa - công việc đòi hỏi nhiều thời gian, kinh nghiệm chuyên môn cao và tiềm ẩn sai sót chủ quan.

Sự phát triển mạnh mẽ của học sâu (Deep Learning), đặc biệt là các kiến trúc mạng nơ-ron tích chập (CNN) hiện đại, đã mở ra khả năng hỗ trợ bác sĩ trong việc sàng lọc và phân loại khối u não từ ảnh MRI với độ chính xác cao. Tuy nhiên, một trong những rào cản lớn nhất khi ứng dụng AI vào y tế là tính “hộp đen” (black-box) của mô hình - bác sĩ không thể biết được mô hình đã “nhìn” vào đâu để đưa ra kết luận. Vì vậy, việc tích hợp các kỹ thuật Trí tuệ nhân tạo có thể giải thích (Explainable AI - XAI), cụ thể là Grad-CAM, để trực quan hoá vùng ảnh mà mô hình tập trung, là yêu cầu gần như bắt buộc để tăng độ tin cậy khi triển khai thực tế.

Xuất phát từ định hướng cá nhân theo mảng Data - Data Science, Machine Learning và Deep Learning, nhóm em lựa chọn đề tài xây dựng hệ thống BrainTumorAI: một hệ thống hoàn chỉnh từ khâu xử lý dữ liệu, huấn luyện, đánh giá mô hình đến triển khai API và giao diện web, nhằm vận dụng tổng hợp kiến thức về học sâu, khoa học dữ liệu và kỹ thuật phần mềm.

2. Mục tiêu nghiên cứu

Đề tài hướng đến các mục tiêu cụ thể sau:

- Xây dựng pipeline xử lý và phân tích khám phá dữ liệu (EDA) cho bộ ảnh MRI não.
- Huấn luyện và so sánh hai kiến trúc mạng CNN - EfficientNetB0 và DenseNet121 - theo chiến lược 2-phase transfer learning.
- Đánh giá mô hình bằng các chỉ số Accuracy, Precision, Recall, F1-score, AUC-ROC và Confusion Matrix trên tập kiểm thử độc lập.

- Tích hợp Grad-CAM để trực quan hoá vùng ảnh quyết định của mô hình, tăng tính minh bạch (Explainability).
- Xây dựng Backend API bằng FastAPI và giao diện Web bằng Next.js để triển khai mô hình thành sản phẩm demo hoàn chỉnh.

3. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu: Ảnh MRI não thuộc 4 lớp - Glioma (u thần kinh đệm), Meningioma (u màng não), Pituitary (u tuyến yên) và No Tumor (không có khối u).

Phạm vi nghiên cứu:

- Trong phạm vi: xử lý ảnh MRI, huấn luyện mô hình phân loại 4 lớp, giải thích kết quả bằng Grad-CAM, xây dựng giao diện Web AI demo.
- Ngoài phạm vi: thay thế chẩn đoán của bác sĩ, chẩn đoán lâm sàng chính thức, phân tích hồ sơ bệnh án điện tử, hỗ trợ ảnh CT-Scan hoặc X-Ray.

4. Phương pháp nghiên cứu

Báo cáo sử dụng kết hợp phương pháp nghiên cứu lý thuyết (tổng hợp cơ sở lý thuyết về CNN, Transfer Learning, Explainable AI) và phương pháp thực nghiệm (xây dựng, huấn luyện, đánh giá mô hình trên bộ dữ liệu thực tế, triển khai hệ thống demo và kiểm thử tự động bằng Pytest).

CHƯƠNG 1: CƠ SỞ LÝ THUYẾT

1.1 Tổng quan về khối u não và ảnh MRI

Ảnh cộng hưởng từ (Magnetic Resonance Imaging - MRI) là kỹ thuật chẩn đoán hình ảnh không xâm lấn, sử dụng từ trường và sóng radio để tạo ra hình ảnh chi tiết về cấu trúc não bộ, được xem là tiêu chuẩn vàng trong phát hiện khối u não. Đề tài tập trung vào 4 nhóm đối tượng phân loại:

Lớp	Mô tả
Glioma	U thần kinh đệm - phát sinh từ tế bào thần kinh đệm (glial cells), có thể ác tính ở mức độ cao.
Meningioma	U màng não - thường lành tính, phát triển chậm, phát sinh từ màng bao quanh não và tủy sống.
Pituitary	U tuyến yên - khối u phát sinh từ tuyến yên, có thể gây rối loạn nội tiết (hormone).
No Tumor	Não bình thường - lớp đối chứng âm tính, không phát hiện khối u.

Bảng 1.1. Bốn lớp phân loại trong bài toán Brain Tumor MRI Classification

1.2 Mạng nơ-ron tích chập (Convolutional Neural Network - CNN)

CNN là kiến trúc mạng nơ-ron nhân tạo chuyên biệt cho dữ liệu dạng lưới như hình ảnh, gồm các lớp tích chập (Convolution) trích xuất đặc trưng cục bộ (cạnh, kết cấu, hình dạng), các lớp gộp (Pooling) giảm chiều dữ liệu và tăng tính bất biến với phép tịnh tiến, và lớp kết nối đầy đủ (Fully Connected) cho tác vụ phân loại cuối cùng. CNN hiện là kiến trúc nền tảng cho hầu hết bài toán thị giác máy tính, bao gồm phân tích ảnh y tế.

1.3 Học chuyển giao (Transfer Learning)

Transfer Learning là kỹ thuật tận dụng một mô hình đã được huấn luyện trước (pretrained) trên tập dữ liệu lớn (ví dụ ImageNet với hơn 1 triệu ảnh, 1000 lớp) để làm điểm khởi đầu cho một bài toán mới có tập dữ liệu nhỏ hơn - như bài toán phân loại ảnh MRI trong đề tài này. Lợi ích chính là rút ngắn thời gian huấn luyện, giảm nguy cơ overfitting khi dữ liệu hạn chế, và tận dụng được các đặc trưng tổng quát (edge, texture, shape) đã học từ tập dữ liệu lớn.

Đề tài áp dụng chiến lược Transfer Learning theo 2 giai đoạn (2-phase fine-tuning):

- Phase 1 - Warm-up: Đóng băng (freeze) toàn bộ backbone đã pretrained, chỉ huấn luyện lớp phân loại (classifier head) mới với tốc độ học cao ($1e-3$) trong một số epoch ngắn.
- Phase 2 - Fine-tuning: Mở băng (unfreeze) toàn bộ mạng, huấn luyện lại với tốc độ học rất nhỏ ($1e-4 \rightarrow 5e-5 \rightarrow 2.5e-5$) để tinh chỉnh toàn bộ trọng số mà không phá vỡ đặc trưng đã học.

1.4 Kiến trúc mô hình sử dụng

1.4.1 *EfficientNetB0*

EfficientNet (Tan & Le, 2019) là họ kiến trúc CNN sử dụng phương pháp compound scaling - mở rộng đồng thời và cân đối ba chiều độ sâu (depth), độ rộng (width) và độ phân giải ảnh đầu vào (resolution) theo một hệ số hợp lý, thay vì chỉ tăng một chiều riêng lẻ như các kiến trúc trước đó. EfficientNetB0 là phiên bản nhỏ nhất trong họ EfficientNet, có kích thước nhẹ (khoảng 5MB) nhưng vẫn đạt độ chính xác cạnh tranh, phù hợp để triển khai production với tốc độ suy luận nhanh.


1.4.2 *DenseNet121*

DenseNet (Huang và cộng sự, 2017) là kiến trúc CNN trong đó mỗi lớp được kết nối trực tiếp với tất cả các lớp phía sau nó theo kiểu feed-forward dày đặc (dense connectivity), giúp tăng cường lan truyền đặc trưng (feature propagation), giảm hiện tượng vanishing gradient và tái sử dụng đặc trưng hiệu quả. Trong đề tài, DenseNet121 được dùng làm mô hình đối chiếu (benchmark) để so sánh với EfficientNetB0, đặc biệt được đánh giá cao trong các bài toán ảnh y tế nhờ khả năng trích xuất đặc trưng chi tiết.

1.5 Trí tuệ nhân tạo có thể giải thích - Grad-CAM

Grad-CAM (Gradient-weighted Class Activation Mapping - Selvaraju và cộng sự, 2017) là kỹ thuật XAI sử dụng gradient của lớp dự đoán mục tiêu, lan truyền ngược đến lớp tích chập cuối cùng của mạng, để tạo ra bản đồ nhiệt (heatmap) thể hiện mức độ quan trọng của từng vùng ảnh đối với quyết định phân loại. Trong bài toán ảnh y tế, Grad-CAM giúp bác sĩ kiểm chứng trực quan liệu mô hình có thực sự tập trung vào

vùng tổn thương hay đang “học vẹt” theo các đặc trưng nhiễu không liên quan, qua đó tăng độ tin cậy khi ứng dụng AI hỗ trợ chẩn đoán.



Hình 1.1. Heatmap Grad-CAM thực tế

CHƯƠNG 2: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

2.1 Phát biểu bài toán

Bài toán được phát biểu như sau: Cho một ảnh MRI não đầu vào, hệ thống cần dự đoán ảnh thuộc một trong bốn lớp (glioma, meningioma, pituitary, notumor), đồng thời sinh ra bản đồ Grad-CAM minh họa vùng ảnh mà mô hình đã dựa vào để đưa ra quyết định, và hiển thị toàn bộ kết quả trên giao diện web thân thiện với người dùng.

2.2 Yêu cầu hệ thống

2.2.1 Yêu cầu chức năng

Mã	Chức năng	Mô tả
FR-01	Tải ảnh MRI	Người dùng upload ảnh MRI từ máy tính và xem trước ảnh.
FR-02	Phân loại khối u	Hệ thống nhận ảnh, dự đoán loại khối u và trả về xác suất.
FR-03	Giải thích dự đoán	Sinh bản đồ Grad-CAM, hiển thị vùng ảnh AI tập trung.
FR-04	Hiển thị kết quả	Hiển thị ảnh gốc, nhãn dự đoán, độ tin cậy và heatmap.
FR-05	Quản lý mô hình	Lưu trọng số mô hình đã huấn luyện và nạp lại khi suy luận.

Bảng 2.1. Danh sách yêu cầu chức năng

2.2.2 Yêu cầu phi chức năng


Mã	Tiêu chí	Mô tả
NFR-01	Hiệu năng	Thời gian dự đoán dưới 5 giây/ảnh.
NFR-02	Độ chính xác	Mục tiêu Accuracy tổng thể $\geq 90\%$.
NFR-03	Khả năng sử dụng	Giao diện đơn giản, thao tác dễ dàng.
NFR-04	Khả năng mở rộng	Có thể mở rộng sang Segmentation, Detection, bổ sung dữ liệu mới.

Bảng 2.2. Danh sách yêu cầu phi chức năng

2.3 Kiến trúc tổng thể hệ thống

Kiến trúc hệ thống được thiết kế theo luồng xử lý tuần tự từ dữ liệu đầu vào đến kết quả hiển thị cho người dùng:

Ảnh MRI → *Tiền xử lý dữ liệu (Data Preprocessing)* → *Mô hình CNN (EfficientNetB0 / DenseNet121)* → *(a) Phân loại khối u & (b) Grad-CAM* → *Kết quả có thể giải thích (ảnh + xác suất + heatmap)* → *Web Dashboard*.



Hình 2.1. Sơ đồ kiến trúc hệ thống

2.4 Kiến trúc mã nguồn dự án

Dự án được tổ chức theo cấu trúc module hoá rõ ràng, tách biệt giữa xử lý dữ liệu, huấn luyện, suy luận, giải thích và ứng dụng web:

Thư mục	Vai trò
app/backend	API suy luận bằng FastAPI (nhận ảnh, trả kết quả phân loại + Grad-CAM).
app/frontend	Giao diện Web bằng Next.js (App Router) + Tailwind CSS.

src/preprocessing	Tiền xử lý dữ liệu, augmentation, phân tích EDA (dataset.py, eda.py, transforms.py).
src/training	Định nghĩa mô hình, vòng lặp huấn luyện 2 giai đoạn, đánh giá (models.py, train.py, evaluate.py).
src/inference	Suy luận (predict.py) và xuất mô hình sang ONNX (export_onnx.py).
src/explainability	Tích hợp Grad-CAM, tự động phát hiện target layer (gradcam.py).
models/	Lưu trữ checkpoint trọng số mô hình (.pth).
reports/	Lưu kết quả huấn luyện, biểu đồ so sánh, log training.
notebooks/	Notebook phân tích EDA và so sánh/đánh giá mô hình.
tests/	Bộ kiểm thử tự động bằng Pytest cho toàn bộ pipeline.


Bảng 2.3. Cấu trúc thư mục và vai trò các module chính

2.5 Bộ dữ liệu (Dataset)

Đề tài sử dụng bộ dữ liệu Brain Tumor MRI Dataset - bộ ảnh MRI não công khai được tổng hợp trên nền tảng Kaggle, gồm hơn 7.000 ảnh chụp MRI được gán nhãn theo 4 lớp cân bằng (glioma, meningioma, pituitary, notumor). Cụ thể trong quá trình huấn luyện và đánh giá:

Thuộc tính	Giá trị
Tổng số ảnh sử dụng	5.600 ảnh huấn luyện/validation + 1.600 ảnh kiểm thử độc lập
Số lớp	4 lớp - cân bằng 1.400 ảnh/lớp (tập train/val)
Tỉ lệ Train / Validation	80% / 20% (stratified split, random seed = 42)
Định dạng ảnh	JPG, PNG
Kích thước ảnh đầu vào	Resize về 224×224 pixel

Bảng 2.4. Thống kê bộ dữ liệu sử dụng




Hình 2.2. Biểu đồ phân bố số lượng ảnh theo từng lớp

2.6 Tiền xử lý dữ liệu và Data Augmentation


Nhằm tăng khả năng tổng quát hoá của mô hình và hạn chế overfitting trên tập dữ liệu y tế vốn có kích thước hạn chế, các kỹ thuật augmentation sau được áp dụng trong quá trình huấn luyện:

Kỹ thuật	Tham số	Mục đích
Random Horizontal Flip	$p = 0.5$	Lật ngang ngẫu nhiên, tăng đa dạng góc nhìn
Random Rotation	$\pm 20^\circ$	Xoay ảnh ngẫu nhiên, mô phỏng sai lệch tư thế chụp
Color Jitter	brightness 0.2, contrast 0.2, saturation 0.1	Mô phỏng sai khác độ sáng/tương phản giữa các máy MRI
Random Affine	shear 10° , scale 0.9–1.1	Mô phỏng biến dạng hình học nhẹ
Random Erasing	$p = 0.1$	Che ngẫu nhiên vùng ảnh nhỏ, buộc mô hình học đặc trưng toàn diện


Bảng 2.5. Các kỹ thuật Data Augmentation áp dụng trong huấn luyện




Hình 2.3. Phân bố kích thước ảnh



Hình 2.4. Phân bố cường độ sáng trung bình theo nhãn



Hình 2.5. Phân bố ảnh mẫu



Hình 2.6. Ảnh trung bình

CHƯƠNG 3: HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH

3.1 Cấu hình huấn luyện

Cả hai mô hình EfficientNetB0 và DenseNet121 đều được huấn luyện với cùng một cấu hình thực nghiệm để đảm bảo tính công bằng khi so sánh:

Tham số	Giá trị
Phase 1 (Warm-up classifier)	5 epoch, learning rate = $1e-3$
Phase 2 (Full fine-tuning)	tối đa 35 epoch, learning rate = $1e-4 \rightarrow 5e-5 \rightarrow 2.5e-5$
Batch size	32
Weight decay	$1e-4$
LR Scheduler	Giảm 0.5 lần sau 3 epoch không cải thiện (ReduceLROnPlateau)
Early Stopping	patience = 7 epoch, khôi phục trọng số tốt nhất
Phần cứng huấn luyện	CPU (có tạm dừng an toàn 5 giây/epoch để bảo vệ phần cứng)
Random seed	42 (đảm bảo khả năng tái lập kết quả)

Bảng 3.1. Cấu hình huấn luyện áp dụng cho cả hai mô hình

3.2 Kết quả huấn luyện EfficientNetB0

Sau 5 epoch warm-up, mô hình đạt Val Accuracy 66.87%. Bước sang Phase 2 fine-tuning, EarlyStopping kích hoạt sau 18/35 epoch, với kết quả tốt nhất đạt được ở epoch 11:

Chỉ số	Giá trị	Ghi chú
Best Val Accuracy	98.75%	Epoch 11/35
Val Loss tương ứng	0.0450	-
Số epoch thực huấn luyện (Phase 2)	18/35	Dừng sớm nhờ EarlyStopping

Bảng 3.2. Kết quả huấn luyện tốt nhất - EfficientNetB0 (Phase 2)

Classification Report trên tập Validation (1.120 ảnh)

Lớp	Precision	Recall	F1-score	Support
glioma	0.98	0.99	0.99	280
meningioma	0.98	0.98	0.98	280

notumor	1.00	0.99	0.99	280
pituitary	0.99	0.99	0.99	280
macro avg	0.99	0.99	0.99	1120

Bảng 3.3. Classification Report - EfficientNetB0 (Validation set)

Kết quả trên tập kiểm thử độc lập (1.600 ảnh)

Chỉ số	Giá trị
Test Accuracy	94.69%
Macro F1-score	94.57%
Macro Precision	95.06%
Macro Recall	94.69%
Macro AUC-ROC	98.85%
Thời gian suy luận (CPU, 1.600 ảnh)	47.23 giây (~0.030 giây/ảnh)

Bảng 3.4. Hiệu năng EfficientNetB0 trên tập Test độc lập

3.3 Kết quả huấn luyện DenseNet121

DenseNet121 cho thấy khả năng học đặc trưng tổng quát ngay từ epoch đầu của Phase 1 (Val Accuracy 80.98% ngay epoch 1, so với 50.00% của EfficientNetB0), phản ánh ưu thế của kiến trúc dense connectivity khi trích xuất đặc trưng ảnh y tế. EarlyStopping kích hoạt sau 19/35 epoch của Phase 2, đạt kết quả tốt nhất ở epoch 12:


Lớp	Precision	Recall	F1-score	Support
glioma	1.00	0.99	0.99	280
meningioma	0.98	0.99	0.98	280
notumor	1.00	1.00	1.00	280
pituitary	0.99	0.99	0.99	280
macro avg	0.99	0.99	0.99	1120

Bảng 3.5. Classification Report - DenseNet121 (Validation set, best val_acc = 99.46% tại epoch 12)

Chỉ số	Giá trị
Test Accuracy	95.00%
Macro F1-score	94.90%
Macro Precision	95.39%

Macro Recall	95.00%
Macro AUC-ROC	99.00%
Thời gian suy luận (CPU, 1.600 ảnh)	442.39 giây (~0.277 giây/ảnh)

Bảng 3.6. Hiệu năng DenseNet121 trên tập Test độc lập




Hình 3.1. Biểu đồ Training/Validation Loss & Accuracy qua các epoch - EfficientNetB0 và DenseNet121


3.4 So sánh hai mô hình

Chỉ số	EfficientNetB0	DenseNet121	Mô hình tốt hơn
Best Val Accuracy	98.75%	99.46%	DenseNet121
Test Accuracy	94.69%	95.00%	DenseNet121
Macro F1 (Test)	94.57%	94.90%	DenseNet121
Macro AUC-ROC (Test)	98.85%	99.00%	DenseNet121
Val → Test Gap	4.06%	4.46%	EfficientNetB0
Thời gian suy luận (1.600 ảnh)	47.23s	442.39s	EfficientNetB0 (nhanh hơn 9.4 lần)


Bảng 3.7. Bảng so sánh tổng hợp EfficientNetB0 và DenseNet121




Hình 3.2. Biểu đồ so sánh các chỉ số Accuracy / Precision / Recall / F1 / AUC giữa hai mô hình



Hình 3.3. So sánh F1-score theo từng lớp giữa EfficientNetB0 và DenseNet121



Hình 3.4. Ma trận nhầm lẫn (Confusion Matrix) của hai mô hình trên tập Test



Hình 3.5. Đường cong ROC theo từng lớp của hai mô hình

BrainTumorAI v2.0 — Báo Cáo So Sánh Model
EfficientNetB0 vs DenseNet121 | Test Set



Hình 3.6. Dashboard tổng hợp kết quả đánh giá mô hình

CHƯƠNG 4: TRIỂN KHAI HỆ THỐNG

4.1 Backend - FastAPI

Phần Backend được xây dựng bằng FastAPI - framework Python hiệu năng cao cho việc xây dựng REST API, hỗ trợ xử lý bất đồng bộ và tự động sinh tài liệu API (Swagger UI). Các endpoint chính được cung cấp:


Method	Endpoint	Mô tả
GET	/	Thông tin API cơ bản
GET	/health	Kiểm tra trạng thái mô hình và kết nối
GET	/classes	Danh sách 4 nhãn phân loại
POST	/predict	Nhận ảnh MRI, trả về nhãn dự đoán, xác suất và Grad-CAM
GET	/docs	Giao diện thử nghiệm API (Swagger UI)

Bảng 4.1. Danh sách API Endpoint của Backend

Endpoint /predict nhận file ảnh (định dạng PNG/JPEG/JPG, giới hạn tối đa 10MB) và trả về kết quả dạng JSON gồm nhãn dự đoán, độ tin cậy, xác suất của từng lớp, và ảnh heatmap Grad-CAM được mã hoá Base64 để hiển thị trực tiếp trên giao diện web mà không cần lưu file trung gian.

4.2 Frontend - Next.js

Giao diện người dùng được xây dựng bằng Next.js (App Router) kết hợp Tailwind CSS, cho phép người dùng tải ảnh MRI lên, xem trước ảnh, gửi yêu cầu phân loại đến Backend và hiển thị trực quan kết quả gồm: ảnh gốc, nhãn dự đoán, độ tin cậy (%) và bản đồ Grad-CAM chồng lên ảnh gốc.



Hình 4.1. Giao diện phân tích ảnh

4.3 Đóng gói và triển khai bằng Docker

Toàn bộ hệ thống (Backend + Frontend) được đóng gói bằng Docker thông qua file docker-compose.yml, cho phép khởi chạy toàn bộ ứng dụng chỉ với một lệnh duy nhất, giúp đơn giản hoá quá trình triển khai và đảm bảo tính nhất quán giữa các môi trường chạy khác nhau.

4.4 Kiểm thử hệ thống (Testing)

Dự án xây dựng bộ kiểm thử tự động bằng Pytest, bao phủ toàn bộ các thành phần chính của pipeline nhằm đảm bảo chất lượng và khả năng bảo trì mã nguồn:

File kiểm thử	Phạm vi kiểm thử
test_api.py	Kiểm thử các endpoint của Backend FastAPI
test_dataset.py	Kiểm thử việc nạp và xử lý bộ dữ liệu
test_eda.py	Kiểm thử các hàm phân tích khám phá dữ liệu
test_models.py	Kiểm thử khởi tạo và forward pass của các mô hình
test_transforms.py	Kiểm thử pipeline augmentation/transform ảnh
test_utils.py	Kiểm thử các hàm tiện ích (seed, đường dẫn,...)

Bảng 4.2. Danh sách các test case tự động (chạy bằng lệnh: `pytest tests/ -v`)

CHƯƠNG 5: ĐÁNH GIÁ, THẢO LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Điểm mạnh của hệ thống

- Áp dụng đúng chiến lược 2-phase transfer learning - best practice trong lĩnh vực medical imaging.
- Bộ dữ liệu hoàn toàn cân bằng giữa các lớp (1.400 ảnh/lớp), loại bỏ được bias do mất cân bằng dữ liệu (class imbalance).
- Cả hai mô hình đạt Macro AUC-ROC trên 98.8% - mức xuất sắc đối với bài toán phân loại ảnh y tế 4 lớp.
- Có đánh giá trên tập kiểm thử độc lập (1.600 ảnh) - yêu cầu bắt buộc trong các bài toán y tế để tránh đánh giá lạc quan sai lệch.
- Tích hợp Explainable AI (Grad-CAM) giúp tăng tính minh bạch của mô hình.
- Kiến trúc hệ thống module hoá rõ ràng, có bộ kiểm thử tự động, dễ bảo trì và mở rộng.

5.2 Hạn chế và rủi ro cần lưu ý

5.2.1 Khoảng cách Validation $\rightarrow$ Test (Generalization Gap)

Cả hai mô hình đều thể hiện khoảng cách đáng chú ý giữa độ chính xác Validation và Test (EfficientNetB0: 98.75% $\rightarrow$ 94.69%, chênh lệch 4.06%; DenseNet121: 99.46% $\rightarrow$ 95.00%, chênh lệch 4.46%). Trong bài toán ảnh y tế, khoảng cách trên 3% thường là dấu hiệu cảnh báo rằng tập validation ($n = 1.120$) chưa đủ đại diện cho phân phối của tập test, hoặc augmentation chưa đủ mạnh để tổng quát hoá tốt với sự đa dạng cao của ảnh MRI thực tế.

5.2.2 Recall thấp ở lớp Glioma

Đây là vấn đề đáng lưu ý nhất về mặt lâm sàng: cả hai mô hình chỉ đạt Recall khoảng 82% ở lớp glioma trên tập test (EfficientNetB0: 81.75%, DenseNet121: 82.00%), trong khi Precision lại rất cao (trên 99%). Điều này có nghĩa là mô hình rất hiếm khi báo nhầm là glioma khi thực tế không phải, nhưng lại bỏ sót khoảng 18% số ca glioma thực sự. Do glioma là dạng u não có thể ác tính cao, việc bỏ sót ở mức này là chưa đạt yêu cầu nếu dùng làm công cụ sàng lọc độc lập, và cần được cải thiện trước khi xem xét ứng dụng hỗ trợ lâm sàng.

5.2.3 Precision thấp ở lớp Notumor - rủi ro bỏ lọt khối u

Mặc dù Recall của lớp notumor đạt 100% ở cả hai mô hình, Precision lại thấp hơn (EfficientNetB0: 90.50%, DenseNet121: 94.79%), đồng nghĩa với việc một số bệnh nhân thực sự có khối u lại bị mô hình phân loại nhầm thành “khỏe mạnh”. Trên tập test 1.600 ảnh, ước tính EfficientNetB0 bỏ lọt khoảng 42 ca có khối u, trong khi DenseNet121 bỏ lọt khoảng 22 ca - đây là loại sai số nghiêm trọng nhất trong bối cảnh y tế, vì bỏ sót người bệnh nguy hiểm hơn nhiều so với báo động giả cho người khỏe mạnh.

5.2.4 Tốc độ suy luận của DenseNet121

DenseNet121 có thời gian suy luận chậm hơn EfficientNetB0 khoảng 9,4 lần trên CPU (442.39 giây so với 47.23 giây cho 1.600 ảnh, tương đương ~ 0.277 giây/ảnh so với ~ 0.030 giây/ảnh). Tuy nhiên, tốc độ 0,277 giây/ảnh vẫn hoàn toàn đáp ứng yêu cầu thời gian thực trong bối cảnh lâm sàng, do bác sĩ thường mất vài phút để phân tích thủ công một ca MRI.

5.3 Khuyến nghị lựa chọn mô hình

Xét trên tiêu chí an toàn lâm sàng (Clinical Safety) là ưu tiên hàng đầu - cụ thể là số ca bệnh nhân có khối u bị bỏ sót - DenseNet121 được khuyến nghị làm mô hình production, do giảm gần một nửa số ca bỏ lọt khối u so với EfficientNetB0 (22 ca so với 42 ca trên 1.600 ảnh test), trong khi khoảng cách về tốc độ suy luận (0.03s so với 0.277s mỗi ảnh) không ảnh hưởng đáng kể đến trải nghiệm sử dụng thực tế của bác sĩ.

5.4 Hướng phát triển tiếp theo

Ưu tiên cao

- Threshold Tuning: hạ ngưỡng xác suất dự đoán cho lớp glioma (ví dụ > 0.3 thay vì lấy max) để tăng Recall lên trên 95%; nâng ngưỡng cho lớp notumor (ví dụ > 0.8 mới kết luận khỏe mạnh) nhằm giảm thiểu bỏ lọt khối u.
- Cải thiện Recall lớp glioma bằng Focal Loss ($\gamma = 2$, α riêng cho glioma), tăng cường augmentation đặc thù (elastic deformation, brightness jitter) hoặc áp dụng class-weighted sampling.
- Áp dụng Test Time Augmentation (TTA) và Label Smoothing để thu hẹp khoảng cách Validation–Test.

- Bổ sung đánh giá trên tập dữ liệu ngoài (external validation) như BraTS để kiểm tra khả năng tổng quát hoá liên cơ sở dữ liệu (cross-site generalization).

Ưu tiên trung bình và thấp

- Áp dụng K-Fold Cross-Validation ($k=5$) để có khoảng tin cậy (confidence interval) đáng tin cậy hơn.
- Bổ sung Uncertainty Quantification (Monte Carlo Dropout hoặc Deep Ensemble) để mô hình tự báo mức độ tin cậy.
- Mở rộng bài toán sang Segmentation (khoanh vùng chính xác khối u) và Object Detection.
- Thử nghiệm Ensemble giữa EfficientNetB0 và DenseNet121, hoặc Knowledge Distillation để kết hợp ưu điểm tốc độ và độ chính xác của cả hai mô hình.

KẾT LUẬN

Báo cáo đã trình bày toàn bộ quá trình xây dựng hệ thống BrainTumorAI - từ cơ sở lý thuyết về học sâu, học chuyển giao và trí tuệ nhân tạo có thể giải thích, đến thực nghiệm huấn luyện, đánh giá và triển khai hai mô hình CNN (EfficientNetB0 và DenseNet121) cho bài toán phân loại 4 lớp khối u não trên ảnh MRI.

Kết quả thực nghiệm cho thấy cả hai mô hình đều đạt hiệu năng cao, với Test Accuracy trong khoảng 94,69%–95,00% và Macro AUC-ROC trên 98,8%, nằm trong nhóm kết quả tốt so với các hệ thống production-grade được công bố trong y văn giai đoạn 2023–2024. Việc so sánh song song hai kiến trúc cũng cho thấy rõ sự đánh đổi giữa tốc độ suy luận (ưu thế thuộc về EfficientNetB0) và mức độ an toàn lâm sàng liên quan đến việc bỏ sót ca bệnh (ưu thế thuộc về DenseNet121), từ đó đưa ra khuyến nghị lựa chọn mô hình dựa trên tiêu chí ưu tiên an toàn bệnh nhân.

Bên cạnh mô hình học sâu, đề tài cũng xây dựng hoàn chỉnh hệ thống phần mềm đi kèm - Backend API bằng FastAPI, giao diện Web bằng Next.js, đóng gói Docker và bộ kiểm thử tự động bằng Pytest - thể hiện năng lực triển khai một sản phẩm AI hoàn chỉnh từ nghiên cứu đến ứng dụng thực tế, thay vì chỉ dừng lại ở mức thực nghiệm mô hình đơn thuần.

Tuy nhiên, đề tài cũng thẳng thắn chỉ ra các hạn chế còn tồn tại - đặc biệt là khoảng cách Validation–Test và Recall chưa cao ở lớp glioma - như những vấn đề bắt buộc phải giải quyết trước khi có thể xem xét ứng dụng hỗ trợ trong môi trường lâm sàng thực tế. Hệ thống hiện tại chỉ nên được xem là công cụ học thuật và hỗ trợ sàng lọc sơ bộ, không thay thế chẩn đoán chính thức của bác sĩ chuyên khoa.

Về mặt cá nhân, đề tài giúp tôi rèn luyện và củng cố năng lực toàn diện theo định hướng Data Engineering - Data Science - Machine Learning - Deep Learning: từ xử lý dữ liệu, huấn luyện và đánh giá mô hình một cách khoa học, đến kỹ năng triển khai sản phẩm phần mềm thực tế - nền tảng quan trọng cho định hướng nghề nghiệp trong lĩnh vực Data mà tôi đang theo đuổi.

TÀI LIỆU THAM KHẢO

Tiếng Anh

- [1] Tan, M., Le, Q.V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks, Proceedings of the 36th International Conference on Machine Learning (ICML), 6105-6114.
- [2] Huang, G., Liu, Z., Van Der Maaten, L., Weinberger, K.Q. (2017). Densely Connected Convolutional Networks, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 4700-4708.
- [3] Selvaraju, R.R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., Batra, D. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization, Proceedings of the IEEE International Conference on Computer Vision (ICCV), 618-626.
- [4] Cheng, J. (2017). Brain Tumor Dataset, Figshare Dataset, DOI: 10.6084/m9.figshare.1512427.
- [5] Nickparvar, M. (2021). Brain Tumor MRI Dataset, Kaggle, truy cập 07/2026, <https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>
- [6] He, K., Zhang, X., Ren, S., Sun, J. (2016). Deep Residual Learning for Image Recognition, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770-778.

Tài liệu trích dẫn từ Internet

- [7] FastAPI Documentation, truy cập 07/2026, <https://fastapi.tiangolo.com>
- [8] Next.js Documentation, truy cập 07/2026, <https://nextjs.org/docs>
- [9] PyTorch Documentation, truy cập 07/2026, <https://pytorch.org/docs>
- [10] timm - PyTorch Image Models Documentation, truy cập 07/2026, <https://huggingface.co/docs/timm>

PHỤ LỤC

Phụ lục A - Hướng dẫn cài đặt và chạy hệ thống (tóm tắt)

- Backend: `python -m venv venv → pip install -r requirements.txt`
- Frontend: `cd app/frontend → npm install → npm run dev`
- Huấn luyện mô hình: `python src/training/train.py --model-name efficientnet --epochs 40`
- Chạy toàn bộ hệ thống bằng Docker: `docker-compose up -d --build`
- Kiểm thử tự động: `pytest tests/ -v`

Phụ lục B - Liên kết mã nguồn dự án

Toàn bộ mã nguồn, notebook và báo cáo đánh giá mô hình chi tiết được lưu trữ tại kho mã nguồn GitHub của dự án: github.com/Thehy-IT/DS_filnal_Brain.